National Institute of Information Technology

Travaux Pratiques

Segmentation de marché avec l'algorithme Mean Shift

Contexte

Vous travaillez pour un cabinet de conseil en marketing. Un groupe de magasins de vêtements vous transmet un fichier sales.csv, contenant le nombre d'unités vendues pour différents types de hauts (tee-shirts, tuniques, chemisiers, etc.) dans plusieurs boutiques. **Aucune étiquette n'est fournie** : personne ne sait à l'avance combien de "profils de magasins" existent, ni quelles boutiques se ressemblent.

Votre mission : utiliser l'algorithme **Mean Shift** pour segmenter automatiquement ces boutiques en groupes homogènes, sans avoir à décider vous-même du nombre de segments.

Objectifs pédagogiques

À l'issue de ce TP, vous devez être capable de :

- Charger et préparer des données réelles au format CSV pour du clustering
- Estimer automatiquement la bandwidth avec estimate_bandwidth
- Entraîner un modèle MeanShift et en extraire labels, centres et nombre de clusters
- Visualiser des données multidimensionnelles en projetant sur 2 dimensions
- Interpréter les résultats d'un clustering dans un contexte métier concret

Partie 1 — Préparation

1. Récupérez le fichier sales.csv (fourni par l'enseignant, ou construisez-en un jeu de test similaire : une première colonne avec le nom du magasin, suivie de 6 colonnes numériques représentant les ventes de 6 types de hauts).
2. Créez un nouveau script Python dans Spyder, placé dans le même dossier que sales.csv.
3. Importez les bibliothèques nécessaires (csv, numpy, matplotlib.pyplot, et MeanShift, estimate_bandwidth depuis sklearn.cluster).

Question 1 : Pourquoi utilise-t-on ici le module csv de Python plutôt que directement np.loadtxt() comme dans les chapitres précédents ? *(Indice : regardez la première colonne et la première ligne du fichier.)*

Partie 2 — Chargement et préparation des données

Écrivez le code qui :

1. Ouvre le fichier sales.csv avec csv.reader
2. Parcourt chaque ligne avec enumerate()
3. **Met de côté la première ligne** (les en-têtes de colonnes) dans une variable names, sans l'inclure dans les données numériques
4. Convertit chaque ligne restante en liste de flottants (en ignorant la première colonne, qui contient le nom du magasin)
5. Transforme le tout en tableau numpy

Question 2 : Pourquoi exclut-on la première colonne (row[1:]) lors de la construction de X ? Que représente cette colonne, et pourquoi ne doit-elle **jamais** entrer dans le calcul des distances de l'algorithme ?

Question 3 : Affichez X.shape. Combien de magasins (lignes) et combien de variables (colonnes) avez-vous ? On dit que ces données sont "à 6 dimensions" — pourquoi ?

Partie 3 — Entraînement du modèle Mean Shift

1. Estimez la bandwidth avec estimate_bandwidth(X, quantile=0.8, n_samples=len(X)).
2. Entraînez un modèle MeanShift avec cette bandwidth et bin_seeding=True.
3. Extrayez labels, cluster_centers, et num_clusters.
4. Affichez le nombre de clusters trouvés, ainsi qu'un tableau récapitulatif des centres de chaque cluster (avec les noms de colonnes en en-tête, comme dans le slide 26).

Question 4 : Relancez votre script en changeant quantile=0.8 par quantile=0.3, puis par quantile=0.95. Notez le nombre de clusters obtenu dans chaque cas et complétez ce tableau :

Quantile	Nombre de clusters obtenus
0.3	
0.8	
0.95	

Question 5 : D'après vos résultats, confirmez-vous la règle énoncée en cours ("un quantile plus élevé donne une bandwidth plus grande, donc moins de clusters") ? Justifiez avec vos chiffres.

Partie 4 — Visualisation

Vos données ont 6 dimensions — impossible de les afficher directement sur un graphique 2D !

1. Construisez cluster_centers_2d = cluster_centers[:, 1:3], qui ne retient que la 2e et la 3e colonne des centres de clusters.
2. Affichez ces centres avec plt.scatter(), en reprenant le code du slide 24 (bornes des axes calculées avec un offset, titre 'Centers of 2D clusters').

Question 6 : Le code choisit les colonnes d'index 1 et 2 (donc les 2e et 3e variables du fichier). Si vous vouliez plutôt visualiser la relation entre la 1re variable (colonne 0) et la 4e variable (colonne 3), comment modifieriez-vous la ligne cluster_centers_2d = cluster_centers[:, 1:3] ?

Question 7 : Cette visualisation ne montre que **2 des 6 dimensions**. Quelle information perd-on en ne regardant que cette projection 2D ? Deux clusters qui semblent proches sur ce graphique sont-ils nécessairement proches "en réalité" (sur les 6 dimensions) ?

Partie 5 — Interprétation métier

Avec quantile=0.8, vous devriez obtenir **9 clusters** (comme dans le corrigé de référence).

Question 8 : Choisissez 2 clusters dans votre tableau de centres, et rédigez pour chacun une **courte description commerciale** (2-3 phrases), comme le ferait un consultant marketing présentant les résultats à son client. Exemple de format attendu : *"Le cluster X regroupe des magasins qui vendent énormément de tee-shirts (Tsh) mais très peu de pulls (Swe) — probablement des boutiques orientées mode décontractée/été."*

Question 9 : Le directeur des ventes vous demande : *"Pourquoi avez-vous utilisé Mean Shift plutôt que K-Means pour cette analyse ?"* Rédigez une réponse en 3-4 phrases, en vous appuyant sur ce que vous avez appris dans ce chapitre.

Partie 6 — Pour aller plus loin (bonus, facultatif)

Question 10 : Calculez le silhouette score de votre clustering obtenu avec quantile=0.8 (utilisez metrics.silhouette_score(X, labels)). Le score est-il plutôt bon, moyen, ou faible ? Que pourriez-vous en conclure sur la pertinence du choix quantile=0.8 ?

Question 11 : Testez plusieurs valeurs de quantile (comme à la Question 4) et calculez le silhouette score pour chacune. Quelle valeur de quantile semble donner le **meilleur compromis** entre nombre de clusters raisonnable et bonne cohérence interne ?

Consignes de rendu

- Un fichier .py unique et exécutable, avec des commentaires clairs à chaque étape
- Un document (Word ou PDF, à votre convenance) contenant vos réponses aux questions 1 à 9 (10 et 11), accompagné des graphiques et tableaux obtenus

fin